

DEEP LEARNING Y MACHINE LEARNING

Susan Aviles, Karla Almea

>>>>

ÍNDICE

1

DEEP LEARNING

1.1

¿CÓMO FUNCIONA?

1.2

REDES NEURONALES
ARTIFICIALES

1.3

TIPOS DE REDES
NEURONALES
ARTIFICIALES

1.4

ARQUITECTURA DE
REDES NEURONALES

1.5

CARACTERÍSTICAS

>>>>

ÍNDICE

1.6

**VENTAJAS DEEP
LEARNING**

1.7

**DESVENTAJAS DEEP
LEARNING**

2

MACHINE LEARNING

2.1

COMO FUNCIONA

2.2

CARACTERÍSTICAS

2.3

**VENTAJAS DEL
MACHINE LEARNING**

>>>>

ÍNDICE

2.4

**VENTAJAS DEL
MACHINE LEARNING**

2.5

**DIFERENCIAS ENTRE
MACHINE LEARNING Y
DEEP LEARNING**

2.6

**TIPOS DE ALGORITMOS
DE MACHINE LEARNING**

2.7

**TÉCNICAS DE
IMPLEMENTACIÓN**

2.8


**EJEMPLO DE
APLICACIÓN**



1

DEEP LEARNING





DEEP LEARNING


Es un subcampo del aprendizaje automático (machine learning) que se centra en algoritmos y modelos inspirados en la estructura y función del cerebro humano, específicamente en las redes neuronales artificiales conocidas como redes neuronales profundas. El objetivo del Aprendizaje Profundo es permitir que las computadoras aprendan y realicen predicciones o tomen decisiones sin necesidad de ser programadas explícitamente.



/ (AI)

1.1

COMO FUNCIONA




CÓMO FUNCIONA EL DEEP LEARNING

El deep learning funciona mediante el análisis constante de información que recibe y dispone, utilizando una metodología lógica de aprendizaje muy parecida a la del ser humano. Para hacerlo, el programa utiliza redes neuronales artificiales (modelo neuronal inspirado en el funcionamiento cerebral humano). Esto hace que el modelo informático tenga un proceso de aprendizaje más avanzado y moderno



1.2

REDES NEURONALES ARTIFICIALES



REDES NEURONALES ARTIFICIALES

Es un método de la inteligencia artificial que enseña a las computadoras a procesar datos de una manera que está inspirada en la forma en que lo hace el cerebro humano. Se trata de un tipo de aprendizaje profundo, que utiliza los nodos o las neuronas interconectados en una estructura de capas que se parece al cerebro humano. Crea un sistema adaptable que las computadoras utilizan para aprender de sus errores y mejorar continuamente.



1.3

TIPOS DE REDES NEURONALES ARTIFICIALES

Redes neuronales convolucionales (CNN, Convolutional Neural Networks): Las redes neuronales convolucionales son redes neuronales artificiales que han sido diseñadas para procesar matrices estructuradas, como imágenes. Es decir, se encargan de clasificar imágenes basándose en los patrones y objetos que aparecen en ellas, por ejemplo, líneas, círculos o, incluso, ojos y caras.

Recurrent Neural Networks (RNN, redes neuronales recurrentes): Las redes neuronales recurrentes son redes neuronales que usan datos secuenciales o datos de series de tiempo. Este tipo de redes solucionan problemas ordinales o temporales, como la traducción de idiomas, reconocimiento de voz (speech recognition), procesamiento de lenguaje natural (NLP, Natural Language Processing) y captura de imágenes.

Generative Adversarial Networks (GAN, redes generativas antagónicas): Las redes generativas antagónicas consisten en usar 2 redes neuronales artificiales y oponerlas la una a la otra (por eso se les conoce como antagónicas) para generar nuevo contenido o datos sintéticos que pueden hacerse pasar por reales

1.4

ARQUITECTURA DE REDES NEURONALES

Las redes neuronales artificiales están conformadas por 3 tipos de nodos o neuronas:

Capa de entrada: La información del mundo exterior entra en la red neuronal artificial desde la capa de entrada. Los nodos de entrada procesan los datos, los analizan o los clasifican y los pasan a la siguiente capa.

Capa oculta: Las capas ocultas toman su entrada de la capa de entrada o de otras capas ocultas. Las redes neuronales artificiales pueden tener una gran cantidad de capas ocultas. Cada capa oculta analiza la salida de la capa anterior, la procesa aún más y la pasa a la siguiente capa.

Capa de salida: La capa de salida proporciona el resultado final de todo el procesamiento de datos que realiza la red neuronal artificial. Puede tener uno o varios nodos. Por ejemplo, si tenemos un problema de clasificación binaria (sí/no), la capa de salida tendrá un nodo de salida que dará como resultado 1 o 0. Sin embargo, si tenemos un problema de clasificación multiclase, la capa de salida puede estar formada por más de un nodo de salida.

1.5

CARACTERÍSTICAS DE DEEP LEARNING

CARACTERÍSTICAS DE DEEP LEARNING

Representaciones jerárquicas de características: los modelos de deep learning aprenden representaciones de características a diferentes niveles de abstracción, mediante el uso de múltiples capas de neuronas interconectadas.

Capacidad de generalización: los modelos de deep learning son capaces de generalizar el conocimiento aprendido a partir de un conjunto de datos a nuevos datos similares, lo que les permite hacer predicciones precisas en una variedad de tareas.

Aprendizaje de extremo a extremo: los modelos de deep learning pueden aprender directamente de los datos de entrada crudos y producir predicciones finales sin la necesidad de procesamiento manual.



CARACTERÍSTICAS DE DEEP LEARNING

Aprendizaje no supervisado: los modelos de deep learning pueden aprender patrones en los datos sin necesidad de etiquetas o categorías previas, lo que los hace útiles para tareas como la exploración de datos y la detección de anomalías.

Escalabilidad: los modelos de deep learning pueden escalar a conjuntos de datos muy grandes y a tareas más complejas mediante la adición de capas adicionales a la red neuronal.

Transferencia de aprendizaje: los modelos de deep learning entrenados en una tarea pueden ser reutilizados como una base sólida para resolver otras tareas similares con menor cantidad de datos y tiempo de entrenamiento



1.6

VENTAJAS DEL DEEP LEARNING

VENTAJAS DE DEEP LEARNING

Capacidad de aprender características complejas: los modelos de deep learning pueden aprender de manera automática características complejas y abstractas de los datos de entrada, lo que les permite realizar tareas como reconocimiento de voz, reconocimiento de imágenes y traducción automática con gran precisión.

Manejo de grandes conjuntos de datos: los modelos de deep learning pueden manejar grandes conjuntos de datos, lo que les permite aprender patrones significativos y hacer predicciones precisas.

Adaptabilidad y flexibilidad: los modelos de deep learning son muy adaptables y flexibles, lo que les permite manejar diferentes tipos de datos y resolver una variedad de problemas de manera efectiva.



1.7

DESVENTAJAS DEL DEEP LEARNING

DESVENTAJAS DE DEEP LEARNING

Necesidad de grandes cantidades de datos de entrenamiento: El deep learning requiere de grandes cantidades de datos de entrenamiento para obtener buenos resultados.

Alto costo computacional y de almacenamiento: El entrenamiento y ejecución de modelos de deep learning requiere de un alto poder computacional y de almacenamiento, lo que puede ser prohibitivo para algunas aplicaciones.

Dificultad para interpretar los modelos: Los modelos de deep learning son a menudo cajas negras, lo que significa que es difícil entender cómo se están tomando decisiones. Esto puede ser un problema en aplicaciones que requieren explicabilidad y transparencia.






02.

MACHINE LEARNING





MACHINE LEARNING

El Machine Learning se define como “un campo de estudio que brinda a las computadoras la capacidad de aprender sin ser programadas explícitamente”. Esta idea implica entrenar a las computadoras para que realicen tareas de manera inteligente más allá del cálculo numérico tradicional mediante el aprendizaje del entorno circundante a través de ejemplos repetidos



2.1

¿CÓMO FUNCIONA EL MACHINE LEARNING?

¿CÓMO FUNCIONA EL MACHINE LEARNING?

Generalmente involucra tres etapas principales:

- **Preprocesamiento de datos:** esto implica la recopilación y preparación de los datos que se utilizarán para entrenar y validar el modelo de Machine Learning. Esto puede incluir la limpieza de los datos, la eliminación de valores atípicos, la normalización y la selección de características relevantes.
- **Entrenamiento del modelo:** en esta etapa, el algoritmo de Machine Learning utiliza los datos de entrenamiento para ajustar sus parámetros y mejorar su capacidad de hacer predicciones o tomar decisiones.
- **Validación del modelo:** una vez que se ha entrenado el modelo, se utiliza un conjunto de datos de validación para evaluar su rendimiento y verificar que es capaz de hacer predicciones precisas.



2.2

CARACTERÍSTICAS DE MACHINE LEARNING

CARACTERÍSTICAS DE MACHINE LEARNING

A continuación, se detallan sus principales características:

- **El aprendizaje a partir de datos:** el Machine Learning se basa en el uso de datos para entrenar modelos y hacer predicciones o tomar decisiones.
- **La capacidad de adaptarse y mejorar:** los modelos de Machine Learning pueden adaptarse a nuevos datos y mejorar su precisión a medida que se les proporciona más información.
- **La capacidad de generalización:** Los modelos de Machine Learning pueden generalizar a partir de ejemplos específicos y aplicar su conocimiento a nuevos casos.



CARACTERÍSTICAS DE MACHINE LEARNING

- **La necesidad de algoritmos y técnicas específicas:** El Machine Learning utiliza una variedad de algoritmos y técnicas para entrenar modelos y mejorar su desempeño.
- A mayor cantidad de datos, las predicciones se vuelven más confiables y precisas.
- Requieren un proceso de entrenamiento antes de poder generar predicciones.

2.3

VENTAJAS DEL MACHINE LEARNING



VENTAJAS DEL MACHINE LEARNING



Las principales ventajas son las siguientes:

- **Capacidad de modelar patrones complejos:** los algoritmos de Machine Learning pueden modelar patrones complejos en los datos que pueden ser difíciles de detectar a simple vista.
- **Capacidad de manejar grandes cantidades de datos:** los algoritmos de Machine Learning pueden manejar grandes cantidades de datos, lo que puede ser útil en aplicaciones de Big Data.
- **Capacidad de automatización:** el Machine Learning puede automatizar tareas que de otra manera requerirían mucho tiempo y esfuerzo humano, como la clasificación de imágenes o la traducción de idiomas.



VENTAJAS DEL MACHINE LEARNING



Las ventajas de Machine Learning enfocadas a la producción son:

- **Mejora en la eficiencia de producción:** El Machine Learning puede analizar grandes cantidades de datos para identificar patrones y tendencias que permiten optimizar los procesos de producción, reducir los tiempos de inactividad y mejorar la eficiencia general.
- **Reducción de los costos:** Al utilizar el Machine Learning para optimizar los procesos de producción, se pueden identificar y eliminar cuellos de botella y otros problemas que contribuyen a un mayor costo.



VENTAJAS DEL MACHINE LEARNING



- **Mejora de la calidad del producto:** El Machine Learning puede identificar patrones y tendencias que conducen a defectos en los productos y ayudar a ajustar los procesos de producción para mejorar la calidad general del producto.
- **Toma de decisiones mejor informada:** Al analizar grandes cantidades de datos, el Machine Learning puede proporcionar información valiosa para la toma de decisiones en la producción.
- **Mayor flexibilidad y adaptabilidad:** El Machine Learning puede permitir a las empresas adaptarse rápidamente a los cambios en el mercado y la demanda mediante el análisis y la optimización de procesos de producción.



2.4

DESVENTAJAS DEL MACHINE LEARNING

DESVENTAJAS DEL MACHINE LEARNING

Algunas de las desventajas de Machine Learning:

- Adquisición de datos.
- Tiempo y recursos.
- Interpretación de resultados.
- Alta susceptibilidad a errores.

DESVENTAJAS DEL MACHINE LEARNING

Según la Amazon Web Services (AWS), algunas desventajas son:

- El entrenamiento inicial es un proceso costoso y puede llevar mucho tiempo. Puede ser difícil de aplicar si no se dispone de datos suficientes.
- Se trata de un proceso con uso intensivo de computación que requiere una inversión inicial fuerte en caso de que el hardware se configure de manera interna.
- Sin la ayuda de un experto, puede ser un reto interpretar los resultados correctamente y eliminar la incertidumbre.

2.5

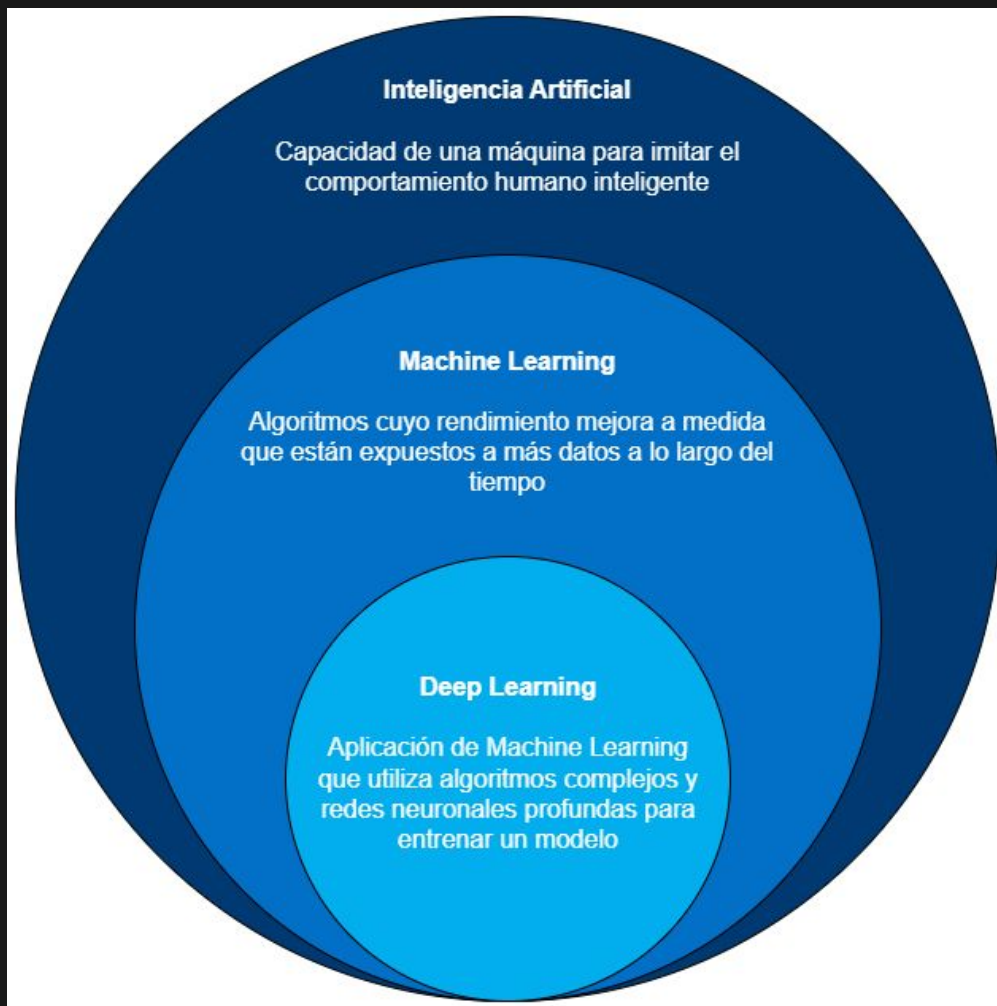
DIFERENCIAS ENTRE MACHINE LEARNING Y DEEP LEARNING

DIFERENCIAS ENTRE MACHINE LEARNING Y DEEP LEARNING



- El Deep Learning es una subcategoría del Machine Learning. Se diferencian en la estructura y complejidad de los algoritmos utilizados.
- En Machine Learning, los algoritmos están diseñados para aprender de los datos a través de la identificación de patrones y tendencias. Este enfoque generalmente utiliza modelos simples que se ajustan a los datos de entrada para hacer predicciones.
- Por otro lado, el Deep Learning se basa en redes neuronales artificiales que imitan el funcionamiento del cerebro humano. Estas redes están diseñadas para identificar patrones aún más complejos en los datos. Debido a su complejidad, el Deep Learning puede manejar grandes conjuntos de datos y proporcionar resultados más precisos en aplicaciones como el reconocimiento de voz, la visión por computadora y la traducción automática.





2.6

TIPOS DE ALGORITMOS DE MACHINE LEARNING

TIPOS DE ALGORITMOS DE MACHINE LEARNING



- **Aprendizaje supervisado:** el aprendizaje automático a menudo utiliza el aprendizaje supervisado para entrenar una función que asigna una entrada a una salida. Utiliza datos de entrenamiento etiquetados y varias muestras de entrenamiento para inferir un proceso. Los modelos de aprendizaje supervisado se entrenan utilizando datos etiquetados, es decir, datos que ya tienen una respuesta conocida.
- **Aprendizaje no supervisado:** es un proceso basado en datos, examina conjuntos de datos no etiquetados sin necesidad de intervención humana. Esto se usa con frecuencia para la extracción de características generativas, la identificación de tendencias es un ejemplo.



TIPOS DE ALGORITMOS DE MACHINE LEARNING



- **Aprendizaje semisupervisado:** es útil cuando los datos no etiquetados son abundantes y la información etiquetada es escasa en el mundo real. El principal objetivo de un modelo de aprendizaje semisupervisado es crear predicciones que sean superiores a las que se realizan utilizando solo los datos etiquetados del modelo.
- **Aprendizaje por refuerzo:** En el aprendizaje por refuerzo, un modelo aprende a través de un proceso de ensayo y error. El modelo recibe una recompensa o un castigo. Sin embargo, no se recomienda usarlo para resolver problemas simples.



2.7


TÉCNICAS DE IMPLEMENTACIÓN DEL MACHINE LEARNING

TÉCNICAS DE IMPLEMENTACIÓN DEL MACHINE LEARNING

- Machine Learning en la nube: esta técnica implica alojar y ejecutar modelos de Machine Learning en plataformas de nube como Google Cloud.
- Machine Learning en dispositivos móviles: esta técnica implica ejecutar modelos de Machine Learning directamente en dispositivos móviles. Esto permite la realización de predicciones y clasificaciones en tiempo real sin necesidad de enviar datos a un servidor remoto
- Machine Learning en el borde (Edge Computing): consiste en ejecutar modelos de Machine Learning en dispositivos conectados a Internet en el borde de la red, como sensores y cámaras de seguridad.

TÉCNICAS DE IMPLEMENTACIÓN DEL MACHINE LEARNING

- Machine Learning embebido: esta técnica implica integrar modelos de Machine Learning en dispositivos integrados, como microcontroladores y sistemas embebidos. Esto permite la realización de tareas de inteligencia artificial directamente en dispositivos integrados sin necesidad de una conexión a Internet
- Machine Learning distribuido: es una técnica que se utiliza para entrenar y mejorar modelos de Machine Learning utilizando múltiples dispositivos y/o servidores de manera distribuida. El proceso se distribuye en múltiples nodos que trabajan en conjunto para procesar los datos y mejorar el modelo de manera más eficiente.



2.8 EJEMPLO DE APLICACIÓN

EJEMPLO DE APLICACIÓN

Se llevó a cabo el desarrollo de un ejemplo que integra los conceptos de Deep Learning y Machine Learning, haciendo uso de los servicios proporcionados por Google Cloud. En este ejemplo se implementó una aplicación móvil que utiliza un modelo de inteligencia artificial para reconocer cada edificio dentro de una universidad.

Para la construcción del modelo se utilizó TensorFlow en el servicio de Google Colab, cuyo enlace se encuentra en el siguiente sitio:

https://colab.research.google.com/drive/1hHzvjyAPEYTMSTShqMzFVdSNGuKgrI_b?usp=sharing

/[AI]/[AI]/

GRACIAS

ARTI
CIAL
INTE
IGEN
[AI]

Machine Learning y Deep Learning

Autores: Karla Almea¹, Michell Aviles¹

¹Facultad de Ciencias de la Ingeniería – Universidad Técnica Estatal de Quevedo (UTEQ) -

Quevedo – Los Ríos – Ecuador

[kalmeav, michell.aviles2018]@uteq.edu.ec

Resumen. Este trabajo se presenta una revisión detallada sobre dos de las técnicas de inteligencia artificial más populares: Deep Learning y Machine Learning. En el primer apartado, se describe cómo funciona el Deep Learning, destacando su capacidad para procesar grandes cantidades de datos y aprender patrones complejos. Además, se profundiza en el entrenamiento de modelos de aprendizaje profundo, sus características, ventajas y desventajas, así como sus aplicaciones en diversos campos. En la segunda sección, se aborda el Machine Learning, donde se exponen sus características, ventajas y desventajas. Se hace especial énfasis en las diferencias entre el Machine Learning y el Deep Learning, y se presentan los diferentes tipos de algoritmos de Machine Learning existentes. Finalmente, se discuten las técnicas de implementación del Machine Learning, destacando sus beneficios y desafíos. Este paper es una guía útil para aquellos interesados en el campo de la inteligencia artificial y sus aplicaciones en la actualidad.

Palabras claves: Machine Learning, Deep Learning.

1 Introducción

En la última década, el mundo de la tecnología ha sido testigo de una auténtica revolución en el campo del aprendizaje automático y el aprendizaje profundo. Estas disciplinas, conocidas como machine learning y deep learning, respectivamente, han transformado radicalmente la forma en que interactuamos con la tecnología y han abierto las puertas a un sinfín de posibilidades en diversos ámbitos de aplicación [1].

El Machine Learning y el Deep Learning son técnicas de Inteligencia Artificial que han cobrado gran relevancia en los últimos años gracias a su capacidad para analizar grandes cantidades de datos y extraer información relevante de ellos [2].

Por ende, el machine learning, o aprendizaje automático, se refiere a la capacidad de los sistemas informáticos de aprender y mejorar automáticamente a partir de los datos sin ser explícitamente programados [3]. A través de algoritmos y modelos matemáticos, las máquinas pueden reconocer patrones complejos, realizar predicciones precisas y tomar decisiones basadas en la información proporcionada [4].

Por otra lado, el deep learning se basa en redes neuronales artificiales inspiradas en el funcionamiento del cerebro humano y es capaz de abordar problemas aún más

complejos y extraer representaciones de alto nivel de los datos. Esta tecnología ha sido fundamental en avances como la visión por computadora avanzada, el procesamiento de lenguaje natural, la traducción automática y los vehículos autónomos [3].

En este trabajo se explorarán las características, ventajas y desventajas de ambos enfoques, así como sus diferencias fundamentales y los tipos de algoritmos que se utilizan en cada caso. Además, se presentarán diversas técnicas de implementación del Machine Learning, desde el uso de la nube hasta la incorporación de modelos en dispositivos embebidos. Todo ello con el objetivo de comprender mejor el potencial de estas tecnologías y las posibilidades que ofrecen en ámbitos como la industria, la salud o la seguridad.

2 Deep Learning

El Aprendizaje Automático es un campo de la inteligencia artificial que se enfoca en el desarrollo de algoritmos que puedan aprender a partir de los datos, sin la necesidad de ser explícitamente programados. El objetivo es construir sistemas que puedan mejorar su desempeño en una tarea específica a medida que reciben más datos [5].

Dentro del Aprendizaje Automático, el Deep Learning es una rama del aprendizaje automático (machine learning) que se enfoca en el uso de algoritmos inspirados en la estructura y función del cerebro humano para aprender a partir de datos complejos [6]. El término "profundo" hace referencia al uso de redes neuronales artificiales profundas, que se componen de múltiples capas de neuronas interconectadas para realizar tareas de clasificación, reconocimiento de patrones, predicción y generación de contenido [5].

Estas redes neuronales se componen de múltiples capas de neuronas interconectadas que procesan la información de entrada de manera incremental, aprendiendo patrones cada vez más complejos a medida que avanzan a través de las capas [7]. Las redes se componen de docenas o incluso cientos de «capas» de neuronas, cada una de las cuales recibe e interpreta información de la capa anterior.

Deep learning impulsa muchos servicios y aplicaciones de inteligencia artificial (IA) que mejoran la automatización, realizando tareas analíticas y físicas sin intervención humana. La tecnología de deep learning reside detrás de muchos productos y servicios de uso cotidiano (como los asistentes digitales, los controles de TV habilitados por voz y la detección de fraudes con tarjeta de crédito), así como de tecnologías emergentes (como los automóviles autónomos) [8].

2.1 ¿Cómo funciona?

El deep learning funciona mediante el análisis constante de información que recibe y dispone, utilizando una metodología lógica de aprendizaje muy parecida a la del ser humano. Para hacerlo, el programa utiliza redes neuronales artificiales (modelo

neuronal inspirado en el funcionamiento cerebral humano). Esto hace que el modelo informático tenga un proceso de aprendizaje más avanzado y moderno [9].

Para poder hacer estos análisis, el sistema de Deep Learning se basa en sus redes neuronales artificiales (RNA, neural networks). Las redes neuronales de DL son una estructura de algoritmos de varias capas. Estas redes neuronales identifican patrones y clasifican diferentes tipos de información. Las diferentes capas de las redes neuronales sirven como filtro, yendo desde los elementos más generales a los más sutiles, aumentando la probabilidad de detectar y generar un resultado correcto. Por tanto, cuando un sistema de deep learning tiene que reconocer un objeto, lo compara con aquellos que ya conoce [9].

2.2 Redes neuronales artificiales

Una red neuronal es un método de la inteligencia artificial que enseña a las computadoras a procesar datos de una manera que está inspirada en la forma en que lo hace el cerebro humano [10]. Se trata de un tipo de aprendizaje profundo, que utiliza los nodos o las neuronas interconectados en una estructura de capas que se parece al cerebro humano. Crea un sistema adaptable que las computadoras utilizan para aprender de sus errores y mejorar continuamente. De esta forma, las redes neuronales artificiales intentan resolver problemas complicados, como la realización de resúmenes de documentos o el reconocimiento de rostros, con mayor precisión [11].

2.3 Como funcionan las redes neuronales

El cerebro humano es lo que inspira la arquitectura de las redes neuronales. Las células del cerebro humano, llamadas neuronas, forman una red compleja y con un alto nivel de interconexión y se envían señales eléctricas entre sí para ayudar a los humanos a procesar la información [12]. De manera similar, una red neuronal artificial está formada por neuronas artificiales que trabajan juntas para resolver un problema. Las neuronas artificiales son módulos de software, llamados nodos, y las redes neuronales artificiales son programas de software o algoritmos que, en esencia, utilizan sistemas informáticos para resolver cálculos matemáticos [13].

2.4 Tipos de redes neuronales que hay en Deep learning

Convolutional Neural Networks (CNN, redes neuronales convolucionales)

Las redes neuronales convolucionales son redes neuronales artificiales que han sido diseñadas para procesar matrices estructuradas, como imágenes [14]. Es decir, se encargan de clasificar imágenes basándose en los patrones y objetos que aparecen en ellas, por ejemplo, líneas, círculos o, incluso, ojos y caras [15].

Por ello, las CNN suelen usarse en computer vision (visión artificial), ya que pueden operar con imágenes brutas (raw images) y no necesitan hacer un procesamiento previo. Esta cualidad hace que sean muy útiles para aplicaciones visuales de clasificación de imágenes, pero también procesamiento del lenguaje

natural (natural language processing, nlp), ayudando con la clasificación de textos [14].

Recurrent Neural Networks (RNN, redes neuronales recurrentes)

Las redes neuronales recurrentes son redes neuronales que usan datos secuenciales o datos de series de tiempo. Este tipo de redes solucionan problemas ordinales o temporales, como la traducción de idiomas, reconocimiento de voz (speech recognition), procesamiento de lenguaje natural (NLP, Natural Language Processing) y captura de imágenes. Por eso, estas redes se encuentran en tecnologías como Siri o Google translate. En este caso, el procesamiento natural del lenguaje reconoce el habla de una persona. Por ejemplo, se distingue si la persona que está hablando es hombre o mujer, adulto o menor, si tiene acento andaluz o catalán, etc. De esta forma, se analiza la forma de hablar de la persona y se consigue llegar a su idiolecto [16].

Generative Adversarial Networks (GAN, redes generativas antagónicas)

Las redes generativas antagónicas consisten en usar 2 redes neuronales artificiales y oponerlas la una a la otra (por eso se les conoce como antagónicas) para generar nuevo contenido o datos sintéticos que pueden hacerse pasar por reales [17].

Una de las redes genera y la otra funciona como “discriminadora”. La red discriminadora (también conocida como red antagónica) ha sido entrenada para reconocer contenido real y hace de censor para que la red que genera contenido haga contenido que parezca real. Por eso, este tipo de redes son muy usadas para generar imágenes, vídeos y voces [17].

2.5 Arquitectura de una red neuronal

Las redes neuronales artificiales están conformadas por 3 tipos de nodos o neuronas [18]:

Capa de entrada

La información del mundo exterior entra en la red neuronal artificial desde la capa de entrada. Los nodos de entrada procesan los datos, los analizan o los clasifican y los pasan a la siguiente capa.

Capa oculta

Las capas ocultas toman su entrada de la capa de entrada o de otras capas ocultas. Las redes neuronales artificiales pueden tener una gran cantidad de capas ocultas. Cada capa oculta analiza la salida de la capa anterior, la procesa aún más y la pasa a la siguiente capa.

Capa de salida

La capa de salida proporciona el resultado final de todo el procesamiento de datos que realiza la red neuronal artificial. Puede tener uno o varios nodos. Por ejemplo, si tenemos un problema de clasificación binaria (sí/no), la capa de salida tendrá un nodo de salida que dará como resultado 1 o 0. Sin embargo, si tenemos un problema de clasificación multiclase, la capa de salida puede estar formada por más de un nodo de salida.

2.6 Características

A continuación, se presentan algunas de las características principales de Deep learning según los autores Goodfellow et al. [19] :

- **Representaciones jerárquicas de características:** los modelos de deep learning aprenden representaciones de características a diferentes niveles de abstracción, mediante el uso de múltiples capas de neuronas interconectadas.
- **Capacidad de generalización:** los modelos de deep learning son capaces de generalizar el conocimiento aprendido a partir de un conjunto de datos a nuevos datos similares, lo que les permite hacer predicciones precisas en una variedad de tareas.
- **Aprendizaje de extremo a extremo:** los modelos de deep learning pueden aprender directamente de los datos de entrada crudos y producir predicciones finales sin la necesidad de procesamiento manual.

Por otro lado, el autor Chollet [9] describe las siguientes características del deep learning:

- **Aprendizaje no supervisado:** los modelos de deep learning pueden aprender patrones en los datos sin necesidad de etiquetas o categorías previas, lo que los hace útiles para tareas como la exploración de datos y la detección de anomalías.
- **Escalabilidad:** los modelos de deep learning pueden escalar a conjuntos de datos muy grandes y a tareas más complejas mediante la adición de capas adicionales a la red neuronal.
- **Transferencia de aprendizaje:** los modelos de deep learning entrenados en una tarea pueden ser reutilizados como una base sólida para resolver otras tareas similares con menor cantidad de datos y tiempo de entrenamiento.

2.7 Ventajas del Deep learning

El Deep Learning es una rama del Machine Learning que se enfoca en la construcción y entrenamiento de algoritmos de redes neuronales artificiales capaces de aprender de forma autónoma a partir de grandes cantidades de datos. Entre las principales ventajas del Deep Learning se encuentran [9], [12], [19]:

- **Capacidad de aprender características complejas:** los modelos de deep learning pueden aprender de manera automática características complejas y abstractas de los datos de entrada, lo que les permite realizar tareas como reconocimiento de voz, reconocimiento de imágenes y traducción automática con gran precisión.
- **Manejo de grandes conjuntos de datos:** los modelos de deep learning pueden manejar grandes conjuntos de datos, lo que les permite aprender patrones significativos y hacer predicciones precisas.

- **Adaptabilidad y flexibilidad:** los modelos de deep learning son muy adaptables y flexibles, lo que les permite manejar diferentes tipos de datos y resolver una variedad de problemas de manera efectiva.
- **Capacidad de generalización:** los modelos de deep learning pueden generalizar el conocimiento aprendido a partir de un conjunto de datos para hacer predicciones precisas sobre nuevos datos, lo que les permite ser aplicados en una amplia gama de problemas.
- **Aprendizaje de extremo a extremo:** los modelos de deep learning pueden aprender directamente de los datos de entrada crudos y producir predicciones finales sin la necesidad de procesamiento manual, lo que reduce el tiempo y la complejidad de las tareas de procesamiento de datos.

2.8 Desventajas del Deep learning

Aunque el deep learning tiene muchas ventajas, también presenta ciertas desventajas que deben ser consideradas al utilizar esta tecnología. Entre las desventajas se encuentran [9], [12], [19]:

- **Necesidad de grandes cantidades de datos de entrenamiento:** El deep learning requiere de grandes cantidades de datos de entrenamiento para obtener buenos resultados. Esto puede ser un problema en aplicaciones donde no hay suficientes datos disponibles para entrenar un modelo efectivo.
- **Alto costo computacional y de almacenamiento:** El entrenamiento y ejecución de modelos de deep learning requiere de un alto poder computacional y de almacenamiento, lo que puede ser prohibitivo para algunas aplicaciones.
- **Dificultad para interpretar los modelos:** Los modelos de deep learning son a menudo cajas negras, lo que significa que es difícil entender cómo se están tomando decisiones. Esto puede ser un problema en aplicaciones que requieren explicabilidad y transparencia.
- **Posibilidad de sobreajuste:** Los modelos de deep learning pueden ser susceptibles al sobreajuste, lo que significa que el modelo se ajusta demasiado a los datos de entrenamiento y no puede generalizar bien a nuevos datos.

2.9 Aplicación de Deep learning

El Deep Learning se utiliza en una amplia variedad de aplicaciones en diversos campos. A continuación, se mencionan algunos ejemplos [12], [20]:

- **Visión por computadora:** el Deep Learning se utiliza en la detección de objetos, reconocimiento facial, clasificación de imágenes, segmentación de imágenes, seguimiento de objetos y más.

- **Procesamiento de lenguaje natural:** el Deep Learning se utiliza en la traducción automática, la generación de texto, el análisis de sentimientos, la clasificación de texto, el reconocimiento de voz, el chatbot y más.
- **Análisis de datos:** el Deep Learning se utiliza en la predicción de series de tiempo, la detección de anomalías, la clasificación de datos, la agrupación de datos y más.
- **Medicina:** el Deep Learning se utiliza en el diagnóstico de enfermedades, la predicción de resultados de tratamiento, la interpretación de imágenes médicas y más.
- **Robótica:** el Deep Learning se utiliza en el control de robots, la planificación de trayectorias, la percepción del entorno y más.
- **Juegos:** el Deep Learning se utiliza en la creación de agentes de inteligencia artificial que juegan juegos como Go, ajedrez, póker y más.

3 Machine Learning

Una traducción adecuada al término "Machine Learning" en español es "Aprendizaje Automático". El Machine Learning es una de las técnicas más importantes utilizadas en el campo de la Inteligencia Artificial. Según Arthur Samuel, el aprendizaje automático se define como "un campo de estudio que brinda a las computadoras la capacidad de aprender sin ser programadas explícitamente". Esta idea implica entrenar a las computadoras para que realicen tareas de manera inteligente más allá del cálculo numérico tradicional mediante el aprendizaje del entorno circundante a través de ejemplos repetidos [21].

Los algoritmos de aprendizaje automático construyen un modelo matemático basado en datos de muestra, conocidos como datos de entrenamiento, con el fin de hacer predicciones o decisiones sin estar programados explícitamente para realizar la tarea [22].

3.1 ¿Cómo funciona el Machine Learning?

Gerón [23] indica que el proceso de Machine Learning generalmente involucra tres etapas principales:

- **Preprocesamiento de datos:** esto implica la recopilación y preparación de los datos que se utilizarán para entrenar y validar el modelo de Machine Learning. Esto puede incluir la limpieza de los datos, la eliminación de valores atípicos, la normalización y la selección de características relevantes.
- **Entrenamiento del modelo:** en esta etapa, el algoritmo de Machine Learning utiliza los datos de entrenamiento para ajustar sus parámetros y mejorar su capacidad de hacer predicciones o tomar decisiones.
- **Validación del modelo:** una vez que se ha entrenado el modelo, se utiliza un conjunto de datos de validación para evaluar su rendimiento y verificar que es capaz de hacer predicciones precisas.

3.2 Características de Machine Learning

El Machine Learning presenta una serie de características que lo diferencian de otros enfoques de la programación [2]. A continuación, se detallan sus principales características:

- El aprendizaje a partir de datos: el Machine Learning se basa en el uso de datos para entrenar modelos y hacer predicciones o tomar decisiones.
- La capacidad de adaptarse y mejorar: los modelos de Machine Learning pueden adaptarse a nuevos datos y mejorar su precisión a medida que se les proporciona más información.
- La capacidad de generalización: Los modelos de Machine Learning pueden generalizar a partir de ejemplos específicos y aplicar su conocimiento a nuevos casos.
- La necesidad de algoritmos y técnicas específicas: El Machine Learning utiliza una variedad de algoritmos y técnicas para entrenar modelos y mejorar su desempeño.

Según Géron [23], las siguientes características también están presentes en el Machine Learning:

- A mayor cantidad de datos, las predicciones se vuelven más confiables y precisas.
- Requieren un proceso de entrenamiento antes de poder generar predicciones.

3.3 Ventajas y desventajas de Machine Learning

Para saber claramente dónde se utilizará y dónde no se utilizará Machine Learning, es necesario identificar las ventajas y desventajas del aprendizaje automático.

Ventajas de Machine Learning.

Según Flach [24], las ventajas de Machine Learning son las siguientes:

- Capacidad de modelar patrones complejos: los algoritmos de Machine Learning pueden modelar patrones complejos en los datos que pueden ser difíciles de detectar a simple vista.
- Capacidad de manejar grandes cantidades de datos: los algoritmos de Machine Learning pueden manejar grandes cantidades de datos, lo que puede ser útil en aplicaciones de Big Data.
- Capacidad de automatización: el Machine Learning puede automatizar tareas que de otra manera requerirían mucho tiempo y esfuerzo humano, como la clasificación de imágenes o la traducción de idiomas.

Mientras que según Wuest [25], las ventajas de Machine Learning enfocadas a la producción son:

- Mejora en la eficiencia de producción: El Machine Learning puede analizar grandes cantidades de datos para identificar patrones y tendencias que permiten optimizar los procesos de producción, reducir los tiempos de inactividad y mejorar la eficiencia general.

- Reducción de los costos: Al utilizar el Machine Learning para optimizar los procesos de producción, se pueden identificar y eliminar cuellos de botella y otros problemas que contribuyen a un mayor costo.
- Mejora de la calidad del producto: El Machine Learning puede identificar patrones y tendencias que conducen a defectos en los productos y ayudar a ajustar los procesos de producción para mejorar la calidad general del producto.
- Toma de decisiones mejor informada: Al analizar grandes cantidades de datos, el Machine Learning puede proporcionar información valiosa para la toma de decisiones en la producción.
- Mayor flexibilidad y adaptabilidad: El Machine Learning puede permitir a las empresas adaptarse rápidamente a los cambios en el mercado y la demanda mediante el análisis y la optimización de procesos de producción.

Desventajas de Machine Learning.

Chhaya et al. [21] menciona algunas de las desventajas de Machine Learning:

- Adquisición de datos.
- Tiempo y recursos.
- Interpretación de resultados.
- Alta susceptibilidad a errores.

Según la documentación sobre Machine Learning en Amazon Web Services (AWS) [26] algunas desventajas son:

- El entrenamiento inicial es un proceso costoso y puede llevar mucho tiempo. Puede ser difícil de aplicar si no se dispone de datos suficientes.
- Se trata de un proceso con uso intensivo de computación que requiere una inversión inicial fuerte en caso de que el hardware se configure de manera interna.
- Sin la ayuda de un experto, puede ser un reto interpretar los resultados correctamente y eliminar la incertidumbre.

3.4 Diferencias entre Machine Learning y Deep Learning

Goodfellow en su libro “Deep Learning” [27], indica las principales diferencias entre Machine Learning y Deep Learning, las cuales son:

- El Deep Learning es una subcategoría del Machine Learning. Ambos son enfoques para enseñar a las máquinas a aprender a partir de los datos, pero se diferencian en la estructura y complejidad de los algoritmos utilizados.
- En el Machine Learning, los algoritmos están diseñados para aprender de los datos a través de la identificación de patrones y tendencias. Este enfoque generalmente utiliza modelos simples que se ajustan a los datos de entrada para hacer predicciones.
- Por otro lado, el Deep Learning se basa en redes neuronales artificiales (ANN) que imitan el funcionamiento del cerebro humano. Estas redes son mucho más complejas que los modelos del Machine Learning y están diseñadas para identificar patrones aún más complejos en los datos. Debido a su complejidad, el Deep

Learning puede manejar grandes conjuntos de datos y proporcionar resultados más precisos en aplicaciones como el reconocimiento de voz, la visión por computadora y la traducción automática.

Para entender mejor las diferencias entre Inteligencia Artificial (IA), Machine Learning (ML) y Deep Learning (DL) [28], se presenta el siguiente gráfico:

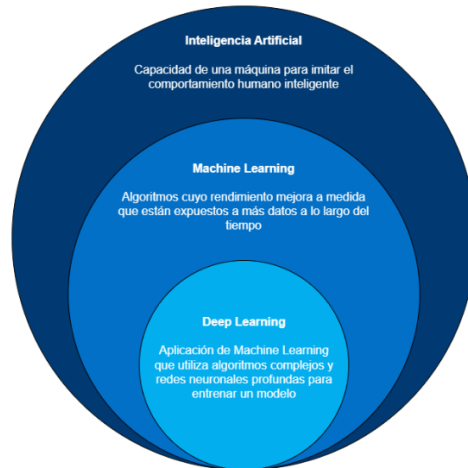


Figura 1 Diferencia entre Inteligencia artificial, Machine Learning y Deep Learning

En resumen, el Machine Learning es un enfoque más simple y generalizado que puede ser aplicado a una amplia gama de aplicaciones, mientras que el Deep Learning es más complejo y se enfoca en aplicaciones específicas que requieren un mayor nivel de precisión en el análisis de datos.

3.5 Tipos de algoritmos de Machine Learning

Según Farzaneh [29], estos algoritmos se pueden clasificar en cuatro estilos de aprendizaje:

- **Aprendizaje supervisado:** utilizando pares de entrada-salida de muestra, el aprendizaje automático a menudo utiliza el aprendizaje supervisado para entrenar una función que asigna una entrada a una salida. Utiliza datos de entrenamiento etiquetados y varias muestras de entrenamiento para inferir un proceso. Los modelos de aprendizaje supervisado se entrenan utilizando datos etiquetados, es decir, datos que ya tienen una respuesta conocida.

¿Qué es el etiquetado de datos?

El etiquetado de datos es el proceso de categorizar los datos de entrada con sus correspondientes valores de salida definidos. Los datos de entrenamiento etiquetados son necesarios para el aprendizaje supervisado [30].

- **Aprendizaje no supervisado:** es un proceso basado en datos, examina conjuntos de datos no etiquetados sin necesidad de intervención humana. Esto se usa con frecuencia para la extracción de características generativas, la identificación de tendencias y estructuras relevantes, agrupaciones de resultados y razones prácticas. La agrupación, la estimación de densidad, el aprendizaje de características, la reducción de dimensionalidad, son algunas de las tareas de aprendizaje no supervisado más populares [29].
- **Aprendizaje semisupervisado:** Debido a que utiliza datos etiquetados y no etiquetados, el aprendizaje semisupervisado combina los enfoques supervisados y no supervisados descritos anteriormente. El aprendizaje semisupervisado es útil cuando los datos no etiquetados son abundantes y la información etiquetada es escasa en el mundo real. El principal objetivo de un modelo de aprendizaje semisupervisado es crear predicciones que sean superiores a las que se realizan utilizando solo los datos etiquetados del modelo. El aprendizaje semisupervisado se utiliza en varias aplicaciones, incluida la categorización de texto, la detección de fraudes, la traducción automática y la detección de fraudes [31].
- **Aprendizaje por refuerzo:** En el aprendizaje por refuerzo, un modelo aprende a través de un proceso de ensayo y error. El modelo recibe una recompensa o un castigo. Sin embargo, no se recomienda usarlo para resolver problemas simples. Es una herramienta sólida para entrenar modelos de IA que pueden ayudar a aumentar la automatización u optimizar la eficiencia operativa de sistemas complejos como robótica, tareas de conducción autónoma, fabricación y logística de la cadena de suministro [31].

3.6 Técnicas de implementación del Machine Learning.

Existen diversas técnicas de implementación del Machine Learning que permiten ejecutar modelos de aprendizaje automático en diferentes entornos, según las necesidades específicas de cada aplicación. Por lo tanto, se presentarán algunas de estas técnicas.

Machine Learning en la nube.

Esta técnica implica alojar y ejecutar modelos de Machine Learning en plataformas de nube como Google Cloud. Las ventajas de esta técnica incluyen la escalabilidad, el acceso a herramientas de Machine Learning integradas y la facilidad de uso [32].

Machine Learning en dispositivos móviles.

En esta técnica implica ejecutar modelos de Machine Learning directamente en dispositivos móviles, como teléfonos inteligentes y tabletas. Esto permite la realización de predicciones y clasificaciones en tiempo real sin necesidad de enviar datos a un servidor remoto [33].

Machine Learning en el borde (Edge Computing).

Consiste en ejecutar modelos de Machine Learning en dispositivos conectados a Internet en el borde de la red, como sensores y cámaras de seguridad. Esto reduce la latencia y el ancho de banda requerido para transmitir datos a un servidor remoto [34].

Machine Learning embebido.

Esta técnica implica integrar modelos de Machine Learning en dispositivos integrados, como microcontroladores y sistemas embebidos. Esto permite la realización de tareas de inteligencia artificial directamente en dispositivos integrados sin necesidad de una conexión a Internet, los modelos de aprendizaje automático se ejecutan en entornos con recursos limitados [35].

Machine Learning distribuido.

Es una técnica que se utiliza para entrenar y mejorar modelos de Machine Learning utilizando múltiples dispositivos y/o servidores de manera distribuida. El proceso se distribuye en múltiples nodos que trabajan en conjunto para procesar los datos y mejorar el modelo de manera más eficiente. Además, esta técnica permite entrenar modelos más grandes y complejos al aprovechar la potencia de procesamiento y almacenamiento distribuido [36].

4 Ejemplo de aplicación

Se llevó a cabo el desarrollo de un ejemplo que integra los conceptos de Deep Learning y Machine Learning, haciendo uso de los servicios proporcionados por Google Cloud. En este ejemplo se implementó una aplicación móvil que utiliza un modelo de inteligencia artificial para reconocer cada edificio dentro de una universidad.

Para la construcción del modelo se utilizó TensorFlow en el servicio de Google Colab, cuyo enlace se encuentra en el siguiente sitio: <https://colab.research.google.com/drive/1hHzvjyAPEYTMSTShqMzFVdSNGuK9rIb?usp=sharing>

La aplicación móvil implementada se encuentra disponible en el siguiente repositorio de Github: <https://github.com/user800-web/edificios>

5 Conclusiones

En conclusión, tanto el deep learning como el machine learning son técnicas de inteligencia artificial con una gran variedad de aplicaciones en diversos campos. El deep learning se destaca por su capacidad para procesar grandes conjuntos de datos y aprender de ellos de manera automática, lo que lo hace especialmente útil en tareas como reconocimiento de voz, visión por computadora, procesamiento de lenguaje natural y otras aplicaciones de alto nivel. Por otro lado, el machine learning es una técnica más amplia que incluye no solo el deep learning, sino también una variedad de algoritmos y enfoques para el aprendizaje automático. En general, estas técnicas están

transformando la forma en que se abordan muchos problemas en la industria, la investigación y otros ámbitos, y se espera que sigan siendo herramientas importantes en el futuro.

6 Bibliografía

- [1] T. Mitchell, “Machine Learning (McGraw-Hill International Editions Computer Science Series): Tom M. Mitchell: 9780071154673,” p. 414, 1997.
- [2] L. Coleta Múgica, “Machine learning en su búsqueda de la responsabilidad ética”.
- [3] C. Janiesch, P. Zschech, and K. Heinrich, “Machine learning and deep learning,” *Electronic Markets*, vol. 31, no. 3, pp. 685–695, Sep. 2021, doi: 10.1007/S12525-021-00475-2/TABLES/2.
- [4] C. M. Bishop, “Pattern Recognition and Machine Learning”.
- [5] Y. Bengio, I. Goodfellow, and A. Courville, “Deep Learning,” 2015.
- [6] N. Rusk, “Deep learning,” 2015, doi: 10.1101/028399.
- [7] C. Janiesch, P. Zschech, and K. Heinrich, “Machine learning and deep learning”, doi: 10.1007/s12525-021-00475-2/Published.
- [8] “¿Qué es Deep Learning?,” *IBM*. <https://www.ibm.com/es-es/topics/deep-learning> (accessed Apr. 24, 2023).
- [9] F. Chollet, “Deep Learning with Python,” ぎょうせい, p. 384, 2017, Accessed: Apr. 24, 2023. [Online]. Available: https://www.google.com.br/books/edition/Deep_Learning_with_Python/Yo3CAQAACAAJ?hl=pt-BR
- [10] X. B. Olabe, “Redes neuronales artificiales y sus aplicaciones”.
- [11] F. Berzal, v Motivación, v El, and C. Humano, “Redes Neuronales Redes Neuronales Artificiales”.
- [12] Y. Lecun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015, doi: 10.1038/NATURE14539.
- [13] Y. Matsuo *et al.*, “Deep learning, reinforcement learning, and world models,” *Neural Networks*, vol. 152, pp. 267–275, Aug. 2022, doi: 10.1016/J.NEUNET.2022.03.037.
- [14] J. Guillermo Guarnizo, S. Riaño Borda, E. C. Camacho Poveda, and A. Mateus Rojas, “Automated Malignant Melanoma Classification Using Convolutional Neural Networks,” *Ciencia e Ingeniería Neogranadina*, vol. 32, no. 2, pp. 171–185, Dec. 2022, doi: 10.18359/RCIN.6270.
- [15] L. N. Smith and N. Topin, “Deep Convolutional Neural Network Design Patterns,” Nov. 2016, Accessed: Apr. 26, 2023. [Online]. Available: <http://arxiv.org/abs/1611.00847>
- [16] I. Bonet Cruz, S. Salazar Martinez, A. R. Abed, G. Abalo, and M. M. G. Lorenzo, “Redes neuronales recurrentes para el análisis de secuencias Recurrent neural network for sequences analysis”.
- [17] A. Cuadrado Cobo, “Generation of images simulating different meteorological conditions using generative adversarial networks (GANs)”.

- Accessed: Apr. 26, 2023. [Online]. Available: <https://digital.csic.es/handle/10261/245767>
- [18] AWS, “¿Qué es una red neuronal? .” <https://aws.amazon.com/es/what-is/neural-network/> (accessed Apr. 26, 2023).
 - [19] I. G. Goodfellow, Y. Bengio, and A. C. Courville, “Deep learning,” *Adaptive computation and machine learning*, p. 775, 2016, Accessed: Apr. 24, 2023. [Online]. Available: <https://dialnet.unirioja.es/servlet/libro?codigo=740537>
 - [20] Y. Gal and Z. Ghahramani, “Bayesian Convolutional Neural Networks with Bernoulli Approximate Variational Inference,” Jun. 2015, Accessed: Apr. 24, 2023. [Online]. Available: <http://arxiv.org/abs/1506.02158>
 - [21] “Machine and Deep Learning in Oncology, Medical Physics and Radiology,” *Machine and Deep Learning in Oncology, Medical Physics and Radiology*, 2022, doi: 10.1007/978-3-030-83047-2.
 - [22] B. Mahesh, “Machine Learning Algorithms - A Review,” *International Journal of Science and Research*, 2018, doi: 10.21275/ART20203995.
 - [23] B. Farnham, S. Tokyo, B. Boston, F. Sebastopol, and T. Beijing, “Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow Concepts, Tools, and Techniques to Build Intelligent Systems SECOND EDITION”.
 - [24] “Machine Learning The Art and Science of Algorithms that Make Sense of Data”.
 - [25] T. Wuest, D. Weimer, C. Irgens, and K. D. Thoben, “Machine learning in manufacturing: advantages, challenges, and applications,” <http://mc.manuscriptcentral.com/tpmr>, vol. 4, no. 1, pp. 23–45, Jun. 2016, doi: 10.1080/21693277.2016.1192517.
 - [26] AWS, “¿Qué es el machine learning? .” <https://aws.amazon.com/es/what-is/machine-learning/> (accessed Apr. 26, 2023).
 - [27] I. Goodfellow, Y. Bengio, and A. Courville, “Deep Learning”.
 - [28] M. Sai, “Artificial Intelligence, Machine Learning, and Deep Learning: Are They All the Same? ,” 2021. <https://www.jyi.org/2021-october/2021/10/27/artificial-intelligence-machine-learning-and-deep-learning-are-they-all-the-same> (accessed Apr. 26, 2023).
 - [29] F. Tajdini, F. Tajdini, and S. Bayat, “Machine Learning Algorithms-A Review”, Accessed: Apr. 26, 2023. [Online]. Available: <https://www.researchgate.net/publication/365635825>
 - [30] AWS, “¿Qué es el machine learning? .” <https://aws.amazon.com/es/what-is/machine-learning/> (accessed Apr. 26, 2023).
 - [31] D. Montes de Oca Zapiain, H. Lim, T. Park, and F. Pourboghrat, “Predicting plastic anisotropy using crystal plasticity and Bayesian neural network surrogate models,” *Materials Science and Engineering A*, vol. 833, Jan. 2022, doi: 10.1016/j.msea.2021.142472.
 - [32] K. Wang, “Cloud Computing for Machine Learning and Cognitive Applications: A Machine Learning Approach,” p. 624, 2017, Accessed: Apr. 26, 2023. [Online]. Available: <https://books.google.com/books?hl=en&lr=&id=82IqDwAAQBAJ&oi=fnd&>

pg=PR5&dq=%22deep+learning%22++%22eucalyptus%22&ots=zaRzI4f6UN&sig=JbM0XFptR2ycrLVR_FxJECf-tZI

- [33] C. Liu, “An Application of Secure Data Aggregation for Privacy-Preserving Machine Learning on Mobile Devices”.
- [34] Z. Zhou, X. Chen, E. Li, L. Zeng, K. Luo, and J. Zhang, “Edge Intelligence: Paving the Last Mile of Artificial Intelligence with Edge Computing”.
- [35] T. S. Ajani, A. L. Imoize, and A. A. Atayero, “An Overview of Machine Learning within Embedded and Mobile Devices—Optimizations and Applications,” *Sensors* 2021, Vol. 21, Page 4412, vol. 21, no. 13, p. 4412, Jun. 2021, doi: 10.3390/S21134412.
- [36] S. Hu, X. Chen, W. Ni, S. Member, E. Hossain, and X. Wang, “Distributed Machine Learning for Wireless Communication Networks: Techniques, Architectures, and Applications”.